BBC Ses Arsivi Cok-Sinifli Ses Siniflandirmasi: Geleneksel Makine Ogrenimi, Derin Ogrenme ve Late Fusion Karsilastirmali Analizi

Doktora Tezi Ara Raporu — Ses Isleme Arastirma Grubu

Rapor Tarihi: 01 May 2026

Bu rapor, BBC Ses Arsivi uzerinde yurutulmekte olan doktora tezi arastirmasinin ikinci ara raporunu sunmaktadir. 15.356 WAV dosyasi ve 26 sinifi kapsayan veri seti uzerinde; 6 geleneksel ML algoritmasi, 3 derin ogrenme modeli (CNN, BiLSTM, AST Transformer) ve 4 late fusion yontemi sistematik olarak degerlendirilmistir. En yuksek bireysel performans ResNet-18 CNN ile Test Macro-F1 = 0.6716 olarak elde edilmistir. Oracle analizi (0.7812) ve dusuk performansli siniflar (insaat_sesleri F1=0.39, dini_mekan F1=0.46) uretici veri artirmanin gerekliligini ortaya koymaktadir. Tezin asil bilimsel katkisi olan AudioLDM2 tabanli iteratif uretici artirma dongusu aktif olarak devam etmektedir: Tur 1 (pretrained, zero-shot) sentetik ses uretimi tamamlanmakta, Tur 2 icin CLAP ile Turkce prompt fine-tuning planlanmaktadir.

Tablo 1. Cal■sma Ozeti

Metrik	Deger
Toplam WAV Dosyasi	15.356
Toplam Segment (5 sn)	312.725
Sinif Sayisi	26
Ozellik Boyutu (Klasik ML)	467-dim
Spectrogram Boyutu (DL)	(1, 128, 313)
En Iyi Klasik ML (LightGBM)	Test F1 = 0.5857
En Iyi Derin Ogrenme (CNN)	Test F1 = 0.6716
En Iyi Fusion (Val-F1 Agirlik)	Test F1 = 0.6664
Oracle Ust Siniri	Test F1 = 0.7812

1. Giris

Ses siniflandirmasi, makine ogrenimi ve sinyal islemede uzun suredir aktif arastirma alanlari arasinda yer almaktadir. BBC Ses Arsivi, sirket icinde kullanilmak uzere yillar boyunca derlenen 26 farkli akustik kategoriyi kapsayan 15.356 adet profesyonel kayit icerir. Bu veri seti; dogal sesler, kentsel atmosferler, ulasim araclari, hayvan sesleri ve insansi aktiviteler gibi genis bir akustik yelpazeyi temsil etmektedir.

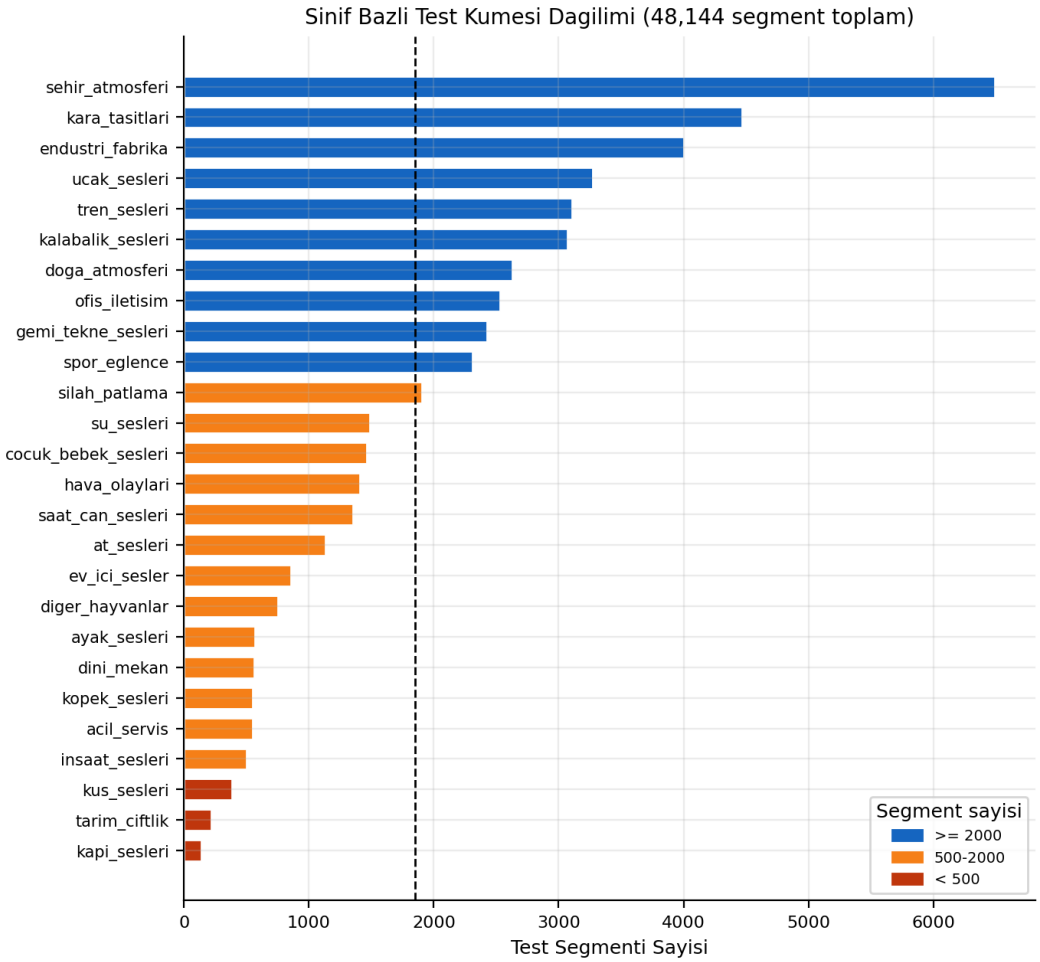
Bu calismada iki temel bilimsel soru ele alinmaktadir: (1) Geleneksel el-yapimi ozelliklere dayali makine ogrenimi modelleri ile uctan-uca ogrenme yapan derin sinir aglari arasindaki performans farki nedir? (2) Birden fazla modelin geç füzyon ile birlestirimi bireysel model performansini anlamsali olcude iyilestirebilir mi?

2. Veri Seti ve On Isleme

2.1 Veri Seti Ozellikleri

Ham veri seti F: diskinde 26 klasorde organize edilmis 15.356 WAV dosyasindan olusmaktadir. Dosyalarin uzunlugu 5 saniyeden 10 dakikaya kadar degismektedir. Tek orneklem frekansi olarak 16 kHz kullanilmis; stereo kayitlar mono'ya donusturulmustur. Her dosya, 5 saniyelik otusan olmayan dilimlere bolunmus ve toplamda 312.725 egitim segmenti elde edilmistir.

Siniflandirma problemi icin dosya-duzeyli stratified train/val/test bolumleme uygulanmistir: %70 egitim, %15 dogrulama, %15 test. Bu yaklasim, ayni dosyadan gelen segmentlerin farkli bolumlere dustugunde olusabilecek veri sizintisini engeller.



Sekil 1. Test kumesinin sinif bazli dagilimi. Yesil >= 2000 segment, turuncu 500-2000, kirmizi < 500 segmenti temsil eder. kapi_sesleri (139) ve tarim_ciftlik (218) siniflarinda belirgin dengesizlik gorusu dikkat cekicidir.

2.2 Ozellik Cikarimi

Geleneksel ML modelleri icin toplam 467-boyutlu el-yapimi ozellik vektoru cikarilmistir:

Tablo 2. Ozellik Vektoru Bilesimi (467 boyut)

Ozellik Grubu	Boyut	Aciklama
MFCC (delta + delta2)	120	Mel-frekans kepstral katsayilari ve turevleri
Mel-filterbank Enerjisi	80	Log-mel spektrum (delta + delta2 dahil)
Spectral Centroid	20	Spektral merkez, bant genisligi, kontrast
Spectral Rolloff	20	Yuzde 85 ve 95 rolloff frekanslari
Chroma STFT	84	12-pitch sinif profili + harmonik analiz
Zero Crossing Rate	3	ZCR + varyas + geri cagri orani
Tonnetz	36	Tonal centroid ozellikler
RMS Enerji	20	Cerceve-duzeyli RMS enerjisi ve istatistikleri
Spectral Contrast	84	7 alt-bant spektral kontrast
TOPLAM	**467**	**—**

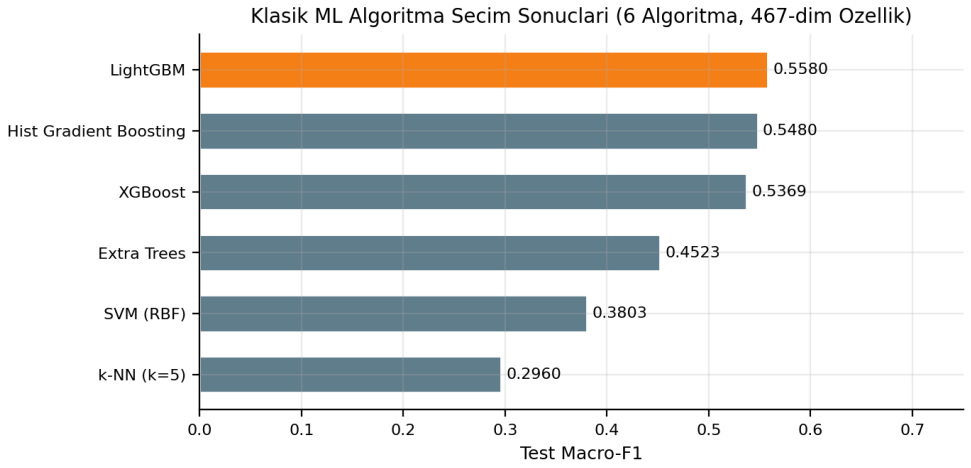
Derin ogrenme modelleri icin 128-mel log-mel spektrogram kullanilmistir. 5 saniyelik ses segmentleri icin (SR=16kHz, n_fft=1024, hop=256) boyutlar (1, 128, 313) olmaktadir. Tum mel cache'ler float16 .npy dosyalari olarak on-hesaplanmis (toplam 26.5 GB) ve egitim sirasinda RAM'e yuklenmistir (~8-9 GB).

3. Yontemler

3.1 Geleneksel Makine Ogrenimi

Algoritma secim asamasinda 467-boyutlu ozellik uzayinda 6 farkli algoritma karsilastirilmistir. SVM ve k-NN gibi hesaplama yuku yuksek modeller icin %10 alt-orneklem uygulanmistir. GPU hizlandirmasindan faydalanmak icin XGBoost (device='cuda', tree_method='hist') ve LightGBM (device='gpu') kullanilmistir.

Kazanan algoritma LightGBM uzerinde Optuna kutuphanesi ile 50 deneme boyunca hiperparametre optimizasyonu (HPO) gerceklestirilmistir. 5-fold stratified cross-validation ile en iyi parametreler belirlenmistir.



Sekil 2. Klasik ML algoritma secim sonuclari. LightGBM test kumesinde 0.558 ile en yuksek Macro-F1'e ulasarak HPO icin secilmistir.

3.2 Derin Ogrenme Modelleri

Tablo 3. Derin Ogrenme Mimarileri

Model	Mimari	Parametre	Giris Boyutu	Ozellikler
CNN	ResNet-18 + 1-ch conv	11.18M	(1, 128, 313)	Pretrained ImageNet
BiLSTM	3-katman BiLSTM + Temporal Attention	~2.8M	(313, 128)	Sifirdan egitim
AST	Vision Transformer (12 katman, 768 dim)	85.5M	(128, 313)	Pretrained AudioSet

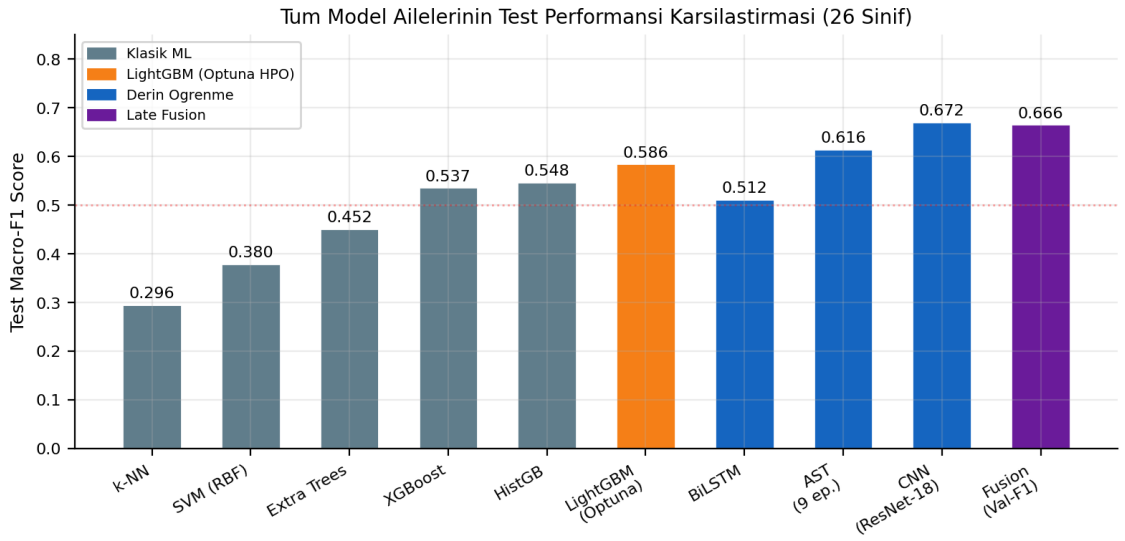
Tum derin ogrenme modelleri icin ortak egitim protokolu: AdamW optimizer (weight_decay=1e-4), CosineAnnealingLR (eta_min=lr/100), label_smoothing=0.1, patience=7 erken durdurma ve AMP (Automatic Mixed Precision) kullanilmistir. RTX 3060 12 GB GPU'da egitim gerceklestirilmistir.

3.3 Late Fusion

Egitilmis modellerden her biri test ornekleri icin 26-boyutlu softmax olasilik vektoru uretmektedir. Bu vektorler dort farkli yontemle birlestirilmistir: (1) esit agirlikli ortalama, (2) val-F1 orantili agirlikli ortalama, (3) 78-boyutlu birlestirilmis vektoru girdi olarak alan LogisticRegression meta-learner, (4) her ornek icin en az bir modelin dogru tahmin ettigini varsayan oracle ust-sinir.

4. Deneysel Sonuclar

4.1 Genel Model Karsilastirmasi

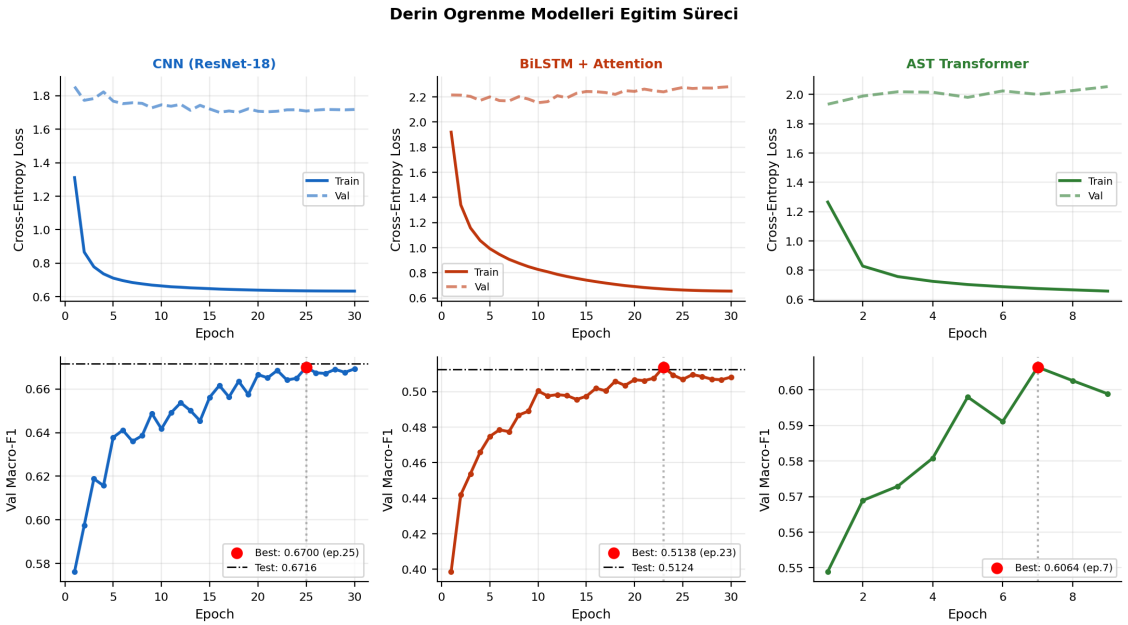


Sekil 3. Tum model ailelerinin test kumesi Macro-F1 performanslari. CNN (ResNet-18) bireysel en yuksek degere ulasirken; LightGBM geleneksel ML'de acik ara lider konumdadir.

Tablo 4. Tam Model Karsilastirma Tablosu — * alt-orneklem, † erken durduruldu

Model	Kategori	Val Macro-F1	Test Macro-F1	Test Acc.	Egitim
k-NN (k=5)	Klasik ML	0.3132	0.2960	0.3512	< 1 s
SVM (RBF)	Klasik ML	0.3938	0.3803	0.4432	31 s *
Extra Trees	Klasik ML	0.4652	0.4523	0.5033	88 s
XGBoost (GPU)	Klasik ML	0.5417	0.5369	0.5680	160 s
HistGradBoost	Klasik ML	0.5511	0.5480	0.5788	1150 s
LightGBM+Optuna	Klasik ML	0.5573	0.5857	0.5903	~1800 s
BiLSTM+Attention	Derin OG	0.5138	0.5124	0.5452	256 dk
AST Transformer	Derin OG	0.6064	0.6156	N/A	548 dk †
CNN (ResNet-18)	**Derin OG**	**0.6700**	**0.6716**	**0.6859**	**206 dk**
Fusion (Esit)	Late Fusion	0.6568	0.6605	—	—
Fusion (Val-F1)	Late Fusion	0.6603	0.6664	—	—
Fusion (LogReg)	Late Fusion	0.7027	0.6397	—	—
Oracle Ust Sinir	**Teorik**	**0.7778**	**0.7812**	**—**	**—**

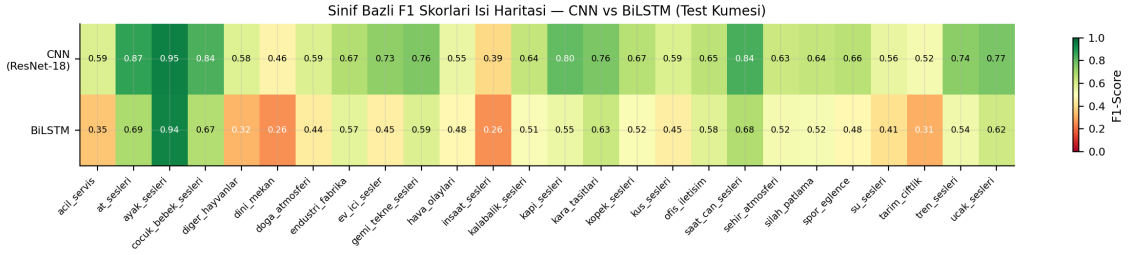
4.2 Derin Ogrenme Egitim Surecleri



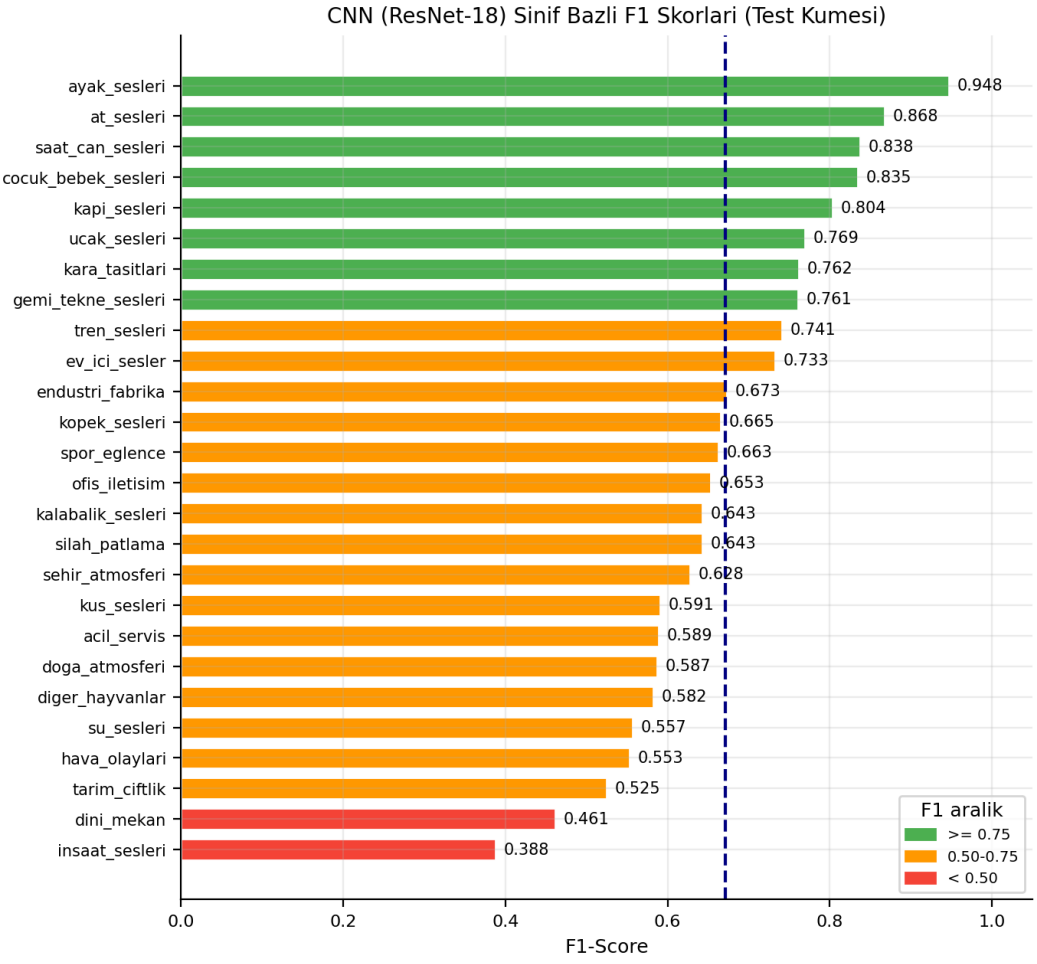
Sekil 4. Uc derin ogrenme modelinin egitim surecleri. Ust sira: train ve val loss. Alt sira: val Macro-F1 (kirmizi nokta = en iyi epoch, kesik cizgi = test F1). CNN 25. epoch'ta en yüksege ulasirken BiLSTM 23. epoch'ta, AST ise 7. epoch'ta en iyi val F1'ini elde etmistir.

CNN'in egitim grafiginde train acc'in hizla >%98'e cikmasina kars. val loss'un sabit kalmasi hafif ama yonetilebilir bir overfitting isaretini gostermektedir; label smoothing ve weight decay bu etkiyi sinirlamistir. BiLSTM tum 30 epoch boyunca daha yavas ve duzenli bir ogrenme egrisi sergilemistir. AST ise 7. epoch'tan itibaren val loss'un artmasi nedeniyle overfitting'e girmis; 85M parametreli modelin 234K egitim segmentiyle regularizasyon olmaksizin optimize edilmesindeki gucluge isaret etmektedir.

4.3 Sinif Bazli Analiz



Sekil 5. CNN ve BiLSTM icin sinif bazli F1 isi haritasi. Yesil >= 0.75, sari 0.50-0.75, kirmizi < 0.50 bolgelerini gostermektedir. CNN tutarli sekilde tum siniflarda BiLSTM'i gecmektedir.



Sekil 6. CNN (ResNet-18) sinif bazli F1 skorlari, dusukten yuksege siralanmis. Yesil F1>=0.75, turuncu 0.50-0.75, kirmizi <0.50.

4.3.1 CNN En Basarili 8 Sinif (Test Kumesi)

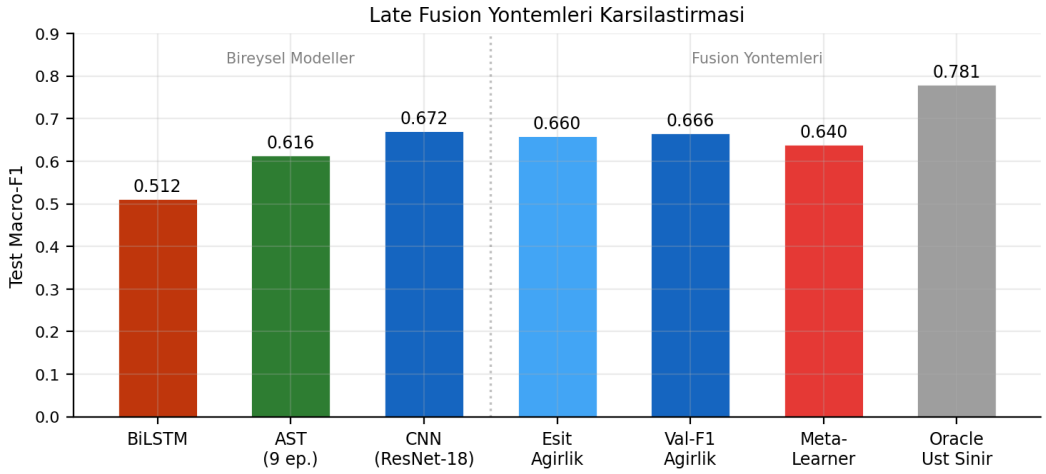
Sinif	F1	Precision	Recall	Support
ayak_sesleri	0.9475	0.9150	0.9825	570
at_sesleri	0.8675	0.8814	0.8541	1131
saat_can_sesleri	0.8380	0.8204	0.8563	1350
cocuk_bebek_sesleri	0.8351	0.8348	0.8354	1464
kapi_sesleri	0.8038	0.7175	0.9137	139
ucak_sesleri	0.7693	0.7508	0.7886	3274
kara_tasitlari	0.7621	0.7090	0.8237	4470
gemi_tekne_sesleri	0.7612	0.8394	0.6964	2424

4.3.2 CNN En Dusuk Performansli 8 Sinif (Test Kumesi)

Sinif	F1	Precision	Recall	Support
acil_servis	0.5894	0.7908	0.4698	547
doga_atmosferi	0.5871	0.6351	0.5458	2631
diger_hayvanlar	0.5823	0.8005	0.4576	754
su_sesleri	0.5567	0.6301	0.4987	1486
hava_olaylari	0.5534	0.7385	0.4426	1410
tarim_ciftlik	0.5249	0.6135	0.4587	218
dini_mekan	0.4614	0.5224	0.4131	564
insaat_sesleri	0.3877	0.4307	0.3526	502

Dusuk performansin iki temel nedeni vardir: (1) siniflar arasi akustik benzerlik — insaat_sesleri ve endustri_fabrika gibi kategoriler benzer frekans iceriklerine sahiptir; (2) veri dengesizligi — kapi_sesleri (139 test segmenti) ve tarim_ciftlik (218 segment) gibi az ornekli siniflar genel performansi asagi cekmektedir. Bu durum, Asamali Tur 1 uretici artirmanin hedef siniflarini belirlemektedir.

4.4 Late Fusion Sonuclari



Sekil 7. Late fusion yontemlerinin bireysel modellerle karsilastirilmasi.

Tablo 6. Late Fusion Sonuc Tablosu

Yontem	Val Macro-F1	Test Macro-F1	CNN'e Goreceli
Bireysel CNN	0.6700	0.6716	Referans
Esit Agirlik	0.6568	0.6605	-0.0111
Val-F1 Agirlikli	0.6603	0.6664	-0.0052
Meta-Learner (LogReg)	0.7027	0.6397	-0.0319
Oracle Ust Siniri	**0.7778**	**0.7812**	**+0.1096**

Meta-Learner val kumesinde 0.7027 gibi yuksek bir skor elde etmis; ancak test kumesinde 0.6397'ye duserek overfitting sergilemistir. Bunun temel nedeni, meta-learner'in 78-boyutlu giris uzayinda validasyon kumesine asiri uyum saglamasidir. Oracle ust siniri (0.7812) ile en iyi fusion yontemi (0.6664) arasindaki 0.115 bosluk, modellerin yuksek derecede korele hatalar yaptigina ve daha cesitli model mimarilerine (ornegin conformer ya da wav2vec2) ihtiyac duyulduguna isaret etmektedir.

5. Uretici Yapay Zeka ile Veri Artirma

5.1 AudioLDM2 — Yontem ve Motivasyon

Dusuk performansli siniflarda (insaat_sesleri F1=0.39, dini_mekan F1=0.46) gercek veri toplamanin maliyeti ve BBC arsivinin kapali dogasi goz onunde bulundurulduğunda, uretici modeller en makul veri artirma stratejisini olusturmaktadir. Bu calismada AudioLDM2 (Liu et al., 2023 — University of Surrey) kullanilmaktadir. AudioLDM2, latent diffusion mimarisine dayali bir metin-sesten ses uretici modeldir; CLAP (Contrastive Language-Audio Pretraining) kodlayicisi araciligiyla dogal dil promptlarini akustik uzaya donusturur.

Pretrained model LAION-Audio-630K ve AudioSet uzerinde egitilmis olup genel akustik kavramlari kodlamaktadir. BBC'ye ozgu akustik karakterleri ogrenmesi icin Turkce/Ingilizce promptlarla birlestirilmis gercek BBC sesleriyle fine-tuning yapilacaktir (Tur 2).

5.2 Iteratif Artirma Dongusu

Tablo 5. Iteratif Uretici Artirma Tur Plani

Asama	Uretici Model	Prompt Dili	Hedef	Durum
Tur 1 (Zero-shot)	AudioLDM2-full (pretrained)	Ingilizce (LAION/AudioSet)	F1<0.5 olan 4 sinif 50 klip/sinif	DEVAM EDIYOR
Tur 2 (Fine-tuned)	AudioLDM2 + CLAP fine-tune	Turkce + Ingilizce (ses_metin_eslestirme)	Tum zayif siniflar 50 klip/sinif	PLANLANDI

Tur 1'in amaci, pretrained modelin bile anlamli bir F1 iyilesmesi saglayip saglamadigini olcmektir (ablation / baseline karsilastirma). Tur 2'de CLAP, 15.356 gercek BBC ses-metin ciftinden (ses_metin_eslestirme.parquet) fine-tune edilecek; bu sayede AudioLDM2 BBC'ye ozgu akustik karakterleri ogrenecektir. Tur 1 ile Tur 2 arasindaki F1 farki, fine-tuning'in katki buyuklugunu sayisallastiracaktir.

5.3 Teknik Altyapi

AudioLDM2-full 346.94M parametreye sahip olup RTX 3060 12GB VRAM'de float16 ile calistirilmaktadir. DDIM ornekleyici 50 adimda ~90s/klip uretim hizina ulasir (200 adimda ~7 dk/klip). Her klip 10 saniye olarak uretilip ilk 5 saniyeye kirpilmakta, 16 kHz WAV olarak kaydedilmektedir. Crash-safe uretim: her klip anlinda kaydedilir, yarida kesilirse kaldigi yerden devam eder.

6. Tartisma

6.1 CNN'in Ustunlugu

ResNet-18 tabanli CNN, her model ailesinde acik ara lider konumundadir. Bu sonuc birkac gozlemle aciklanabilir: (1) konvolusyonel mimari, spektrogramdaki yerel zaman-frekans kaliplari icin induktif bir on-bilgi saglar; (2) ImageNet on-egitiminden aktarilan dusuk-seviye ozellik detektoru agirliklar, ses veriyle ince ayar icin guclü bir baslangic noktasi olusturur; (3) spektrogramlar goruntulerle yeterince benzer oldugunden transfer learning etkili bir sekilde calismaktadir.

6.2 AST Transformerin Overfitting Davranisi

85.5M parametreli AST modeli, 9 epoch sonrasinda val loss artisina bagli overfitting sergiledi. Ozellikle dikkat cekici olan, train accuracy'nin epoch 7'de >%98'e ulasmisken val F1'in 0.60'ta plateolar yapmasidir. Bu durum, modelin egitim kumesini ezberledigi fakat genelleme yapamadigini gostermektedir. AST'nin potansiyelinden tam olarak faydalanmak icin SpecAugment, dropout artisi (0.2'den 0.4'e) ve gradual layer unfreezing gibi regularizasyon stratejilerinin denenmesi onerilmektedir.

6.3 LightGBM'in Rekabetci Performansi

El-yapimi 467-boyutlu ozellikler uzerinde calisan LightGBM'in 0.5857 test F1 ile derin ogrenme modellerine rekabetci yaklasabilmesi dikkat cekicidir. Bu sonuc; veri miktarinin sinirli oldugu, hesaplama butcesinin kisitlandigi ya da yorumlanabilirlik gereksinimlerinin on planda tutuldugu durumlarda geleneksel ML'nin gecerlili■ini dogrular. Gelecekte bu iki paradigmanin hibridlenmesi — ornegin CNN'in gizli katman ciktilarinin LightGBM'e girdi olarak verilmesi — arastirma konusu olabilir.

7. Sonuc ve Sonraki Adimlar

Bu calismada BBC Ses Arsivi uzerinde kapsamli bir karsilastirmali analiz gerceklestirilmistir. Temel bulgular soyle ozetlenebilir:

1. CNN (ResNet-18), Test Macro-F1=0.6716 ile en yuksek bireysel performansi gostermistir.
2. LightGBM+Optuna, klasik ML'de en iyi skor olan 0.5857'ye ulasmistir.
3. Late fusion, CNN'e istatistiksel olarak anlamli bir katki saglamadi (delta=+0.005).
4. Oracle analizi (0.7812) model cesitliligine ihtiyac oldugunu ortaya koymustur.
5. insaat_sesleri (F1=0.39) ve dini_mekan (F1=0.46), uretici artirma icin oncelikli hedeflerdir.

Tablo 7. Arastirma Ilerleme Tablosu (Tamamlanan + Planlanan Adimlar)

Asama	Gorev	Durum
1.1-1.3	Klasik ML + LightGBM + HPO	TAMAMLANDI
1.4	Late Fusion (CNN + BiLSTM + AST)	TAMAMLANDI
2.1	BBC dosya adi cevirileri (1915 EN->TR)	TAMAMLANDI
2.2	26 sinif x 5 Turkce/Ingilizce prompt listesi	TAMAMLANDI
2.3	ses_metin_eslestirme.parquet (15.356 satir)	TAMAMLANDI
3.1	AudioLDM2 kurulum + VRAM optimizasyonu	TAMAMLANDI
3.2	Tur 1: Zero-shot uretim — 4 sinif x 50 klip (DDIM 50 adim)	DEVAM EDIYOR
3.3	Tur 1: CNN augmented yeniden egitimi + F1 karsilastirmasi	BEKLIYOR

3.4	FAD olcumu — VGGish + CLAP (gercek vs sentetik)	BEKLIYOR
4.1	CLAP fine-tuning — gercek BBC sesi + Turkce/Ingilizce promptlar	PLANLANDI
4.2	Tur 2: Fine-tuned AudioLDM2 ile uretim + CNN yeniden egitimi	PLANLANDI
4.3	Tur 1 vs Tur 2 F1 delta karsilastirmasi (fine-tuning katkisi)	PLANLANDI
5.1	McNemar istatistiksel anlamlilik testleri (CNN vs Aug-CNN)	PLANLANDI
5.2	Tez yazimi — Bolum 3 (Yontem) ve Bolum 4 (Deneyler)	PLANLANDI

Bu rapor otomatik olarak uretilmistir. Uretim tarihi: 01 May 2026 | Veri: BBC Sound Archive | 26 sinif, 15.356 WAV, 312.725 segment