# BBC Ses Arsivi Cok-Sinifli Ses Siniflandirmasi: Geleneksel Makine Ogrenimi, Derin Ogrenme ve Late Fusion Karsilastirmali Analizi

Doktora Tezi Ara Raporu — Ses Isleme Arastirma Grubu

Rapor Tarihi: 28 April 2026

Bu rapor, BBC Ses Arsivi uzerinde gerceklestirilen kapsamli ses siniflandirma deneylerinin bulgularini sunmaktadir. 15.356 WAV dosyasi ve 26 sinifi kapsayan veri seti uzerinde; 6 geleneksel makine ogrenimi algoritmasi, 3 derin ogrenme modeli (CNN, BiLSTM, AST Transformer) ve 4 farkli geç füzyon yaklasimi sistematik olarak degerlendirilmistir. En yuksek bireysel performans, pretrained ResNet-18 tabanli CNN modeli ile Test Macro-F1 = 0.6716 olarak elde edilmistir. Geleneksel ML'de LightGBM, Optuna HPO ile Test Macro-F1 = 0.5857 degerine ulasarak en iyi klasik model olmustur. Geç füzyon analizinde Oracle ust sinirinin 0.7812 oldugu saptanmis; model ciktilarinin yuksek korelasyonu nedeniyle Val-F1 agirlikli füzyon bireysel CNN performansini gecememistir.

Tablo 1. Cal■sma Ozeti

| Metrik | Deger |
|---|---|
| Toplam WAV Dosyasi | 15.356 |
| Toplam Segment (5 sn) | 312.725 |
| Sinif Sayisi | 26 |
| Ozellik Boyutu (Klasik ML) | 467-dim |
| Spectrogram Boyutu (DL) | (1, 128, 313) |
| En Iyi Klasik ML (LightGBM) | Test F1 = 0.5857 |
| En Iyi Derin Ogrenme (CNN) | Test F1 = 0.6716 |
| En Iyi Fusion (Val-F1 Agirlik) | Test F1 = 0.6664 |
| Oracle Ust Siniri | Test F1 = 0.7812 |

# 1. Giris

Ses siniflandirmasi, makine ogrenimi ve sinyal islemede uzun suredir aktif arastirma alanlari arasinda yer almaktadir. BBC Ses Arsivi, sirket icinde kullanilmak uzere yillar boyunca derlenen 26 farkli akustik kategoriyi kapsayan 15.356 adet profesyonel kayit icerir. Bu veri seti; dogal sesler, kentsel atmosferler, ulasim araclari, hayvan sesleri ve insansi aktiviteler gibi genis bir akustik yelpazeyi temsil etmektedir.

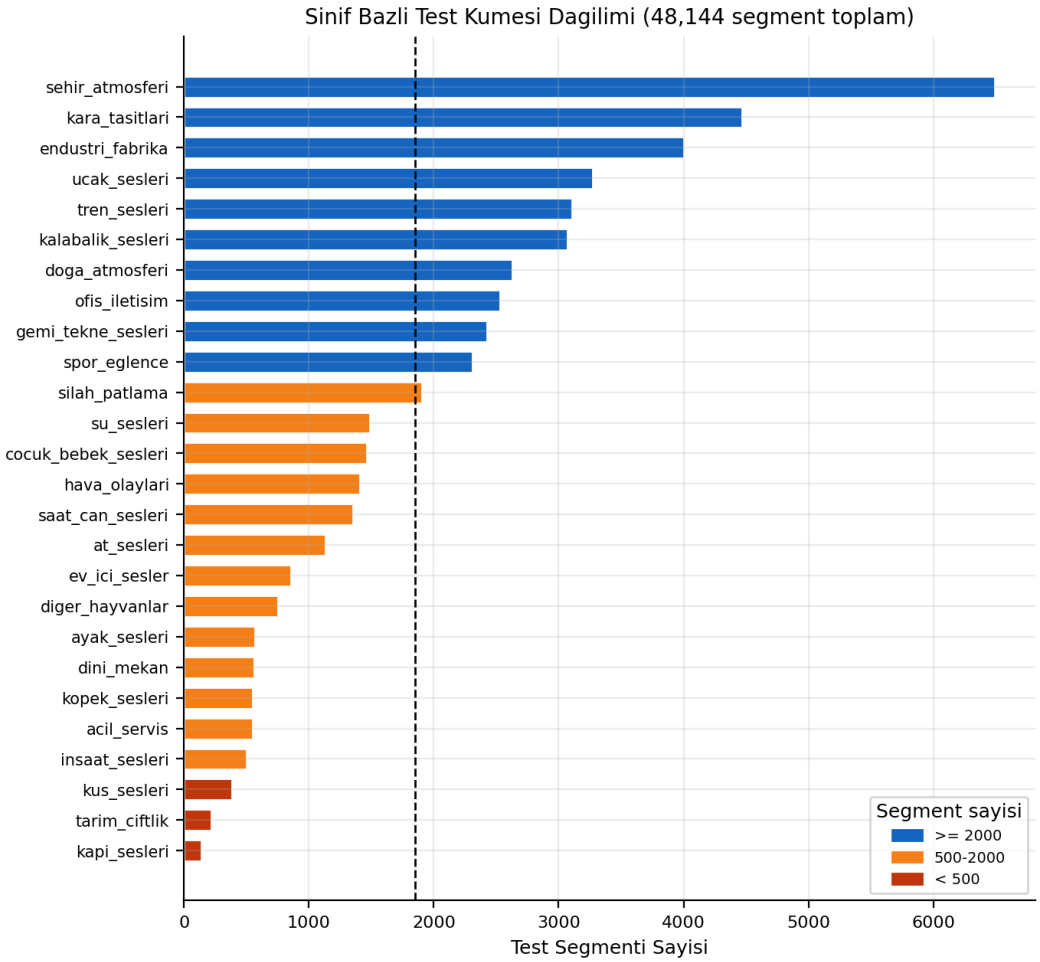
Bu calismada iki temel bilimsel soru ele alinmaktadir: (1) Geleneksel el-yapimi ozelliklere dayali makine ogrenimi modelleri ile uctan-uca ogrenme yapan derin sinir aglari arasindaki performans farki nedir? (2) Birden fazla modelin geç füzyon ile birlestirimi bireysel model performansini anlamsali olcude iyilestirebilir mi?

# 2. Veri Seti ve On Isleme

## 2.1 Veri Seti Ozellikleri

Ham veri seti F: diskinde 26 klasorde organize edilmis 15.356 WAV dosyasindan olusmaktadir. Dosyalarin uzunlugu 5 saniyeden 10 dakikaya kadar degismektedir. Tek orneklem frekansi olarak 16 kHz kullanilmis; stereo kayitlar mono'ya donusturulmustur. Her dosya, 5 saniyelik otusan olmayan dilimlere bolunmus ve toplamda 312.725 egitim segmenti elde edilmistir.

Siniflandirma problemi icin dosya-duzeyli stratified train/val/test bolumleme uygulanmistir: %70 egitim, %15 dogrulama, %15 test. Bu yaklasim, ayni dosyadan gelen segmentlerin farkli bolumlere dustugunde olusabilecek veri sizintisini engeller.



Sekil 1. Test kumesinin sinif bazli dagilimi. Yesil >= 2000 segment, turuncu 500-2000, kirmizi < 500 segmenti temsil eder. kapi_sesleri (139) ve tarim_ciftlik (218) siniflarinda belirgin dengesizlik gorusu dikkat cekicidir.

## 2.2 Ozellik Cikarimi

Geleneksel ML modelleri icin toplam 467-boyutlu el-yapimi ozellik vektoru cikarilmistir:

Tablo 2. Ozellik Vektoru Bilesimi (467 boyut)

| Ozellik Grubu | Boyut | Aciklama |
|---|---|---|
| MFCC (delta + delta2) | 120 | Mel-frekans kepstral katsayilari ve turevleri |
| Mel-filterbank Enerjisi | 80 | Log-mel spektrum (delta + delta2 dahil) |
| Spectral Centroid | 20 | Spektral merkez, bant genisligi, kontrast |
| Spectral Rolloff | 20 | Yuzde 85 ve 95 rolloff frekanslari |
| Chroma STFT | 84 | 12-pitch sinif profili + harmonik analiz |
| Zero Crossing Rate | 3 | ZCR + varyas + geri cagri orani |
| Tonnetz | 36 | Tonal centroid ozellikler |
| RMS Enerji | 20 | Cerceve-duzeyli RMS enerjisi ve istatistikleri |
| Spectral Contrast | 84 | 7 alt-bant spektral kontrast |
| **TOPLAM** | **467** | **—** |

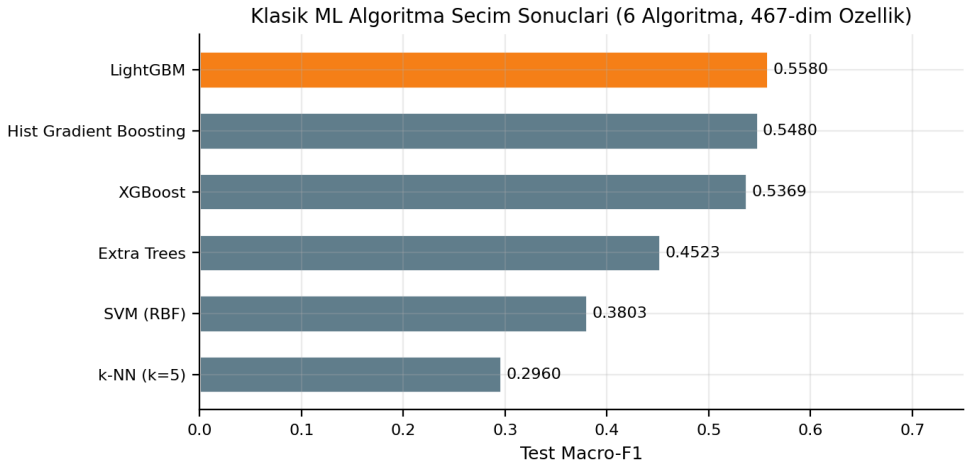
Derin ogrenme modelleri icin 128-mel log-mel spektrogram kullanilmistir. 5 saniyelik ses segmentleri icin (SR=16kHz, n_fft=1024, hop=256) boyutlar (1, 128, 313) olmaktadir. Tum mel cache'ler float16 .npy dosyalari olarak on-hesaplanmis (toplam 26.5 GB) ve egitim sirasinda RAM'e yuklenmistir (~8-9 GB).

# 3. Yontemler

## 3.1 Geleneksel Makine Ogrenimi

Algoritma secim asamasinda 467-boyutlu ozellik uzayinda 6 farkli algoritma karsilastirilmistir. SVM ve k-NN gibi hesaplama yuku yuksek modeller icin %10 alt-orneklem uygulanmistir. GPU hizlandirmasindan faydalanmak icin XGBoost (device='cuda', tree_method='hist') ve LightGBM (device='gpu') kullanilmistir.

Kazanan algoritma LightGBM uzerinde Optuna kutuphanesi ile 50 deneme boyunca hiperparametre optimizasyonu (HPO) gerceklestirilmistir. 5-fold stratified cross-validation ile en iyi parametreler belirlenmistir.




Sekil 2. Klasik ML algoritma secim sonuclari. LightGBM test kumesinde 0.558 ile en yuksek Macro-F1'e ulasarak HPO icin secilmistir.

## 3.2 Derin Ogrenme Modelleri

Tablo 3. Derin Ogrenme Mimarileri

| Model | Mimari | Parametre | Giris Boyutu | Ozellikler |
|---|---|---|---|---|
| CNN | ResNet-18 + 1-ch conv | 11.18M | (1, 128, 313) | Pretrained ImageNet |
| BiLSTM | 3-katman BiLSTM + Temporal Attention | ~2.8M | (313, 128) | Sifirdan egitim |
| AST | Vision Transformer (12 katman, 768 dim) | 85.5M | (128, 313) | Pretrained AudioSet |

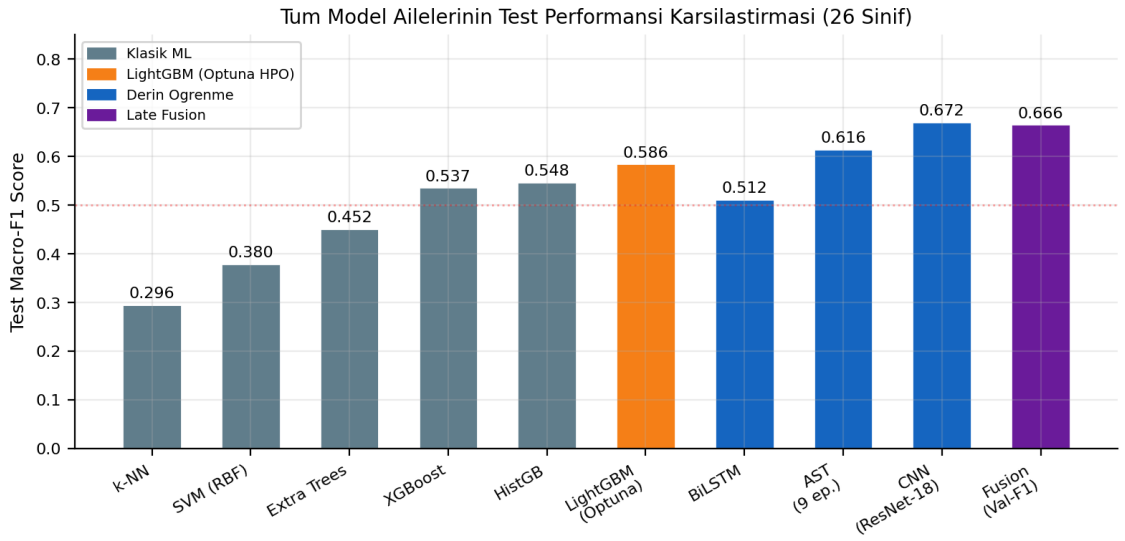
Tum derin ogrenme modelleri icin ortak egitim protokolu: AdamW optimizer (weight_decay=1e-4), CosineAnnealingLR (eta_min=lr/100), label_smoothing=0.1, patience=7 erken durdurma ve AMP (Automatic Mixed Precision) kullanilmistir. RTX 3060 12 GB GPU'da egitim gerceklestirilmistir.

## 3.3 Late Fusion

Egitilmis modellerden her biri test ornekleri icin 26-boyutlu softmax olasilik vektoru uretmektedir. Bu vektorler dort farkli yontemle birlestirilmistir: (1) esit agirlikli ortalama, (2) val-F1 orantili agirlikli ortalama, (3) 78-boyutlu birlestirilmis vektoru girdi olarak alan LogisticRegression meta-learner, (4) her ornek icin en az bir modelin dogru tahmin ettigini varsayan oracle ust-sinir.

# 4. Deneysel Sonuclar

## 4.1 Genel Model Karsilastirmasi

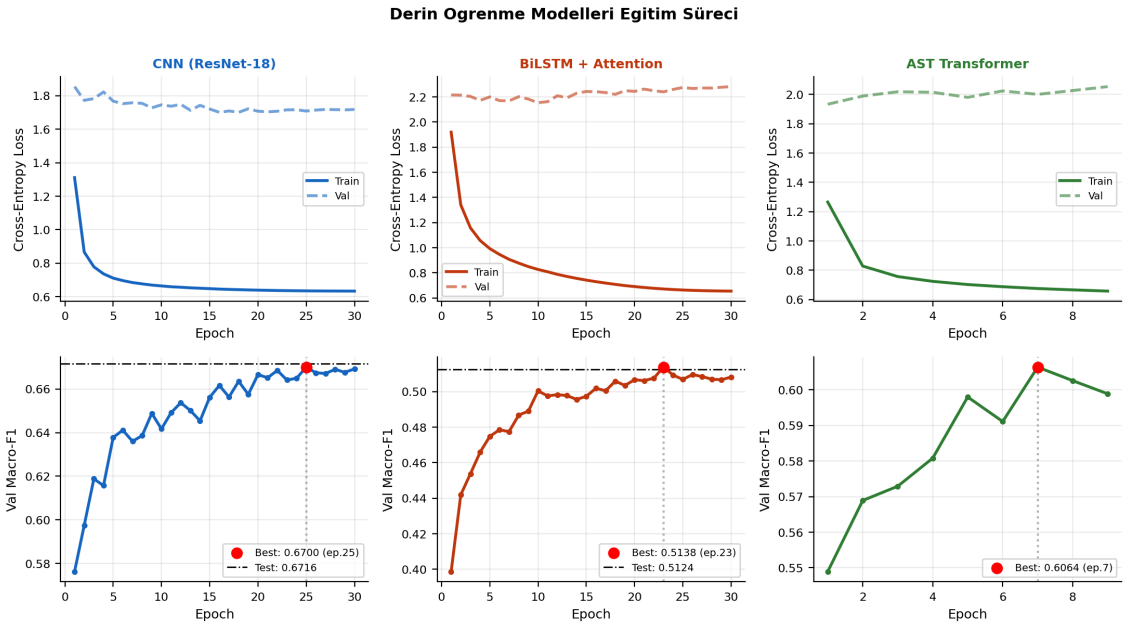



Sekil 3. Tum model ailelerinin test kumesi Macro-F1 performanslari. CNN (ResNet-18) bireysel en yuksek degere ulasirken; LightGBM geleneksel ML'de acik ara lider konumdadir.

Tablo 4. Tam Model Karsilastirma Tablosu — * alt-orneklem, † erken durduruldu

| Model | Kategori | Val Macro-F1 | Test Macro-F1 | Test Acc. | Egitim |
|---|---|---|---|---|---|
| k-NN (k=5) | Klasik ML | 0.3132 | 0.2960 | 0.3512 | < 1 s |
| SVM (RBF) | Klasik ML | 0.3938 | 0.3803 | 0.4432 | 31 s * |
| Extra Trees | Klasik ML | 0.4652 | 0.4523 | 0.5033 | 88 s |
| XGBoost (GPU) | Klasik ML | 0.5417 | 0.5369 | 0.5680 | 160 s |
| HistGradBoost | Klasik ML | 0.5511 | 0.5480 | 0.5788 | 1150 s |
| LightGBM+Optuna | Klasik ML | 0.5573 | 0.5857 | 0.5903 | ~1800 s |
| BiLSTM+Attention | Derin OG | 0.5138 | 0.5124 | 0.5452 | 256 dk |
| AST Transformer | Derin OG | 0.6064 | 0.6156 | N/A | 548 dk † |
| **CNN (ResNet-18)** | **Derin OG** | **0.6700** | **0.6716** | **0.6859** | **206 dk** |
| Fusion (Esit) | Late Fusion | 0.6568 | 0.6605 | — | — |
| Fusion (Val-F1) | Late Fusion | 0.6603 | 0.6664 | — | — |
| Fusion (LogReg) | Late Fusion | 0.7027 | 0.6397 | — | — |
| **Oracle Ust Sinir** | **Teorik** | **0.7778** | **0.7812** | **—** | **—** |

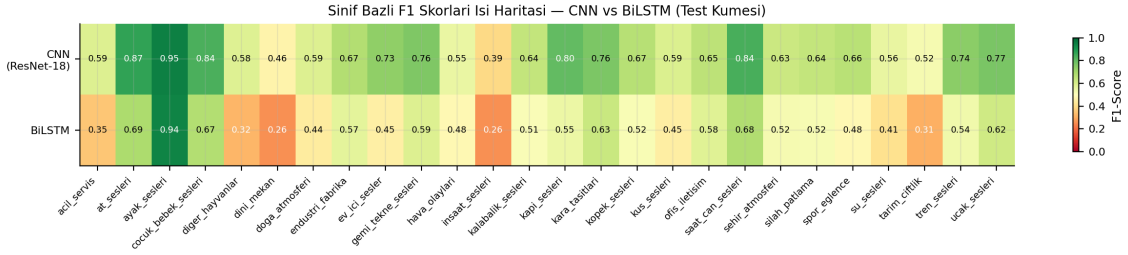
## 4.2 Derin Ogrenme Egitim Surecleri



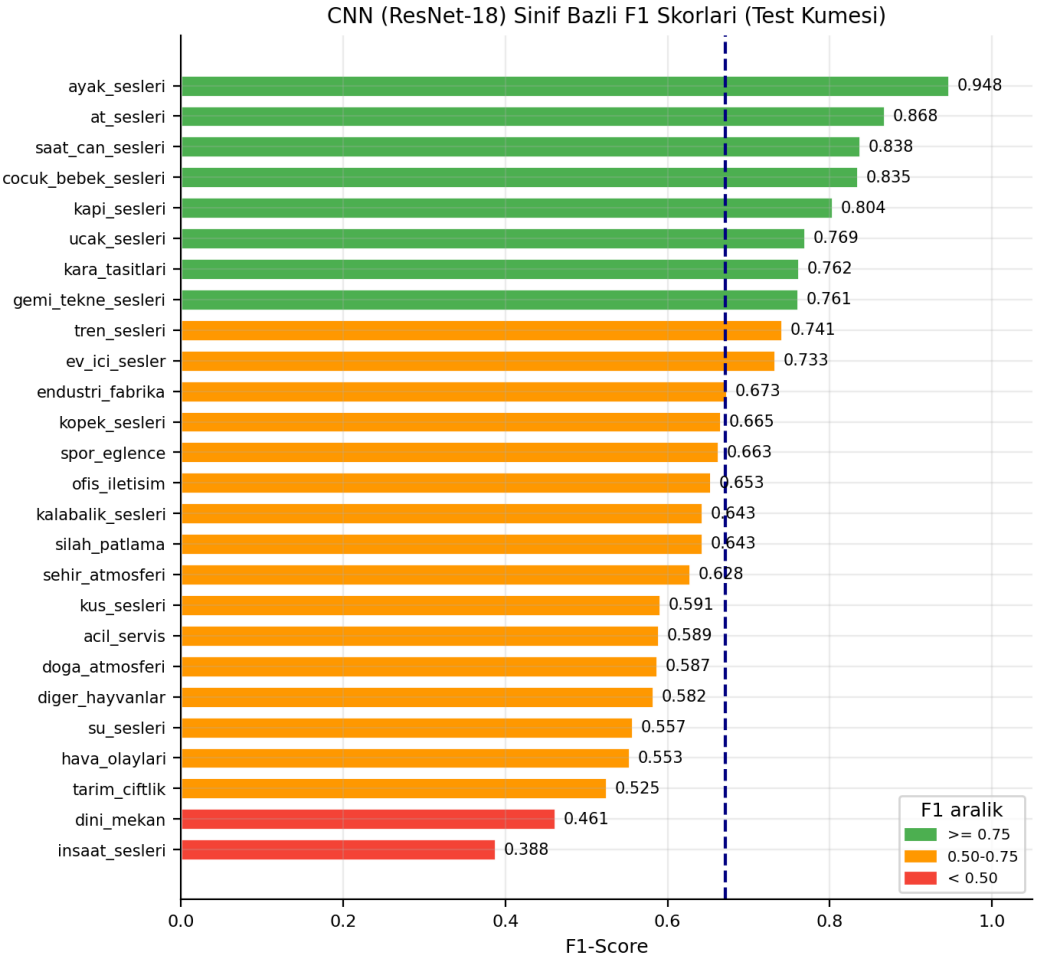

Sekil 4. Uc derin ogrenme modelinin egitim surecleri. Ust sira: train ve val loss. Alt sira: val Macro-F1 (kirmizi nokta = en iyi epoch, kesik cizgi = test F1). CNN 25. epoch'ta en yüksege ulasirken BiLSTM 23. epoch'ta, AST ise 7. epoch'ta en iyi val F1'ini elde etmistir.

CNN'in egitim grafiginde train acc'in hizla >%98'e cikmasina kars. val loss'un sabit kalmasi hafif ama yonetilebilir bir overfitting isaretini gostermektedir; label smoothing ve weight decay bu etkiyi sinirlamistir. BiLSTM tum 30 epoch boyunca daha yavas ve duzenli bir ogrenme egrisi sergilemistir. AST ise 7. epoch'tan itibaren val loss'un artmasi nedeniyle overfitting'e girmis; 85M parametreli modelin 234K egitim segmentiyle regularizasyon olmaksizin optimize edilmesindeki gucluge isaret etmektedir.

## 4.3 Sinif Bazli Analiz




Sekil 5. CNN ve BiLSTM icin sinif bazli F1 isi haritasi. Yesil >= 0.75, sari 0.50-0.75, kirmizi < 0.50 bolgelerini gostermektedir. CNN tutarli sekilde tum siniflarda BiLSTM'i gecmektedir.




Sekil 6. CNN (ResNet-18) sinif bazli F1 skorlari, dusukten yuksege siralanmis. Yesil F1>=0.75, turuncu 0.50-0.75, kirmizi <0.50.

### 4.3.1 CNN En Basarili 8 Sinif (Test Kumesi)

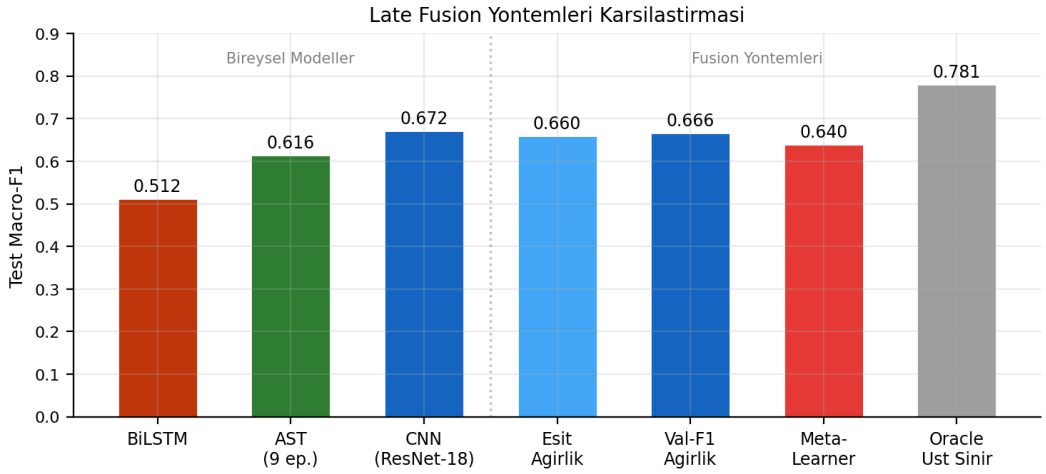
| Sinif | F1 | Precision | Recall | Support |
|---|---|---|---|---|
| ayak_sesleri | 0.9475 | 0.9150 | 0.9825 | 570 |
| at_sesleri | 0.8675 | 0.8814 | 0.8541 | 1131 |
| saat_can_sesleri | 0.8380 | 0.8204 | 0.8563 | 1350 |
| cocuk_bebek_sesleri | 0.8351 | 0.8348 | 0.8354 | 1464 |
| kapi_sesleri | 0.8038 | 0.7175 | 0.9137 | 139 |
| ucak_sesleri | 0.7693 | 0.7508 | 0.7886 | 3274 |
| kara_tasitlari | 0.7621 | 0.7090 | 0.8237 | 4470 |
| gemi_tekne_sesleri | 0.7612 | 0.8394 | 0.6964 | 2424 |

### 4.3.2 CNN En Dusuk Performansli 8 Sinif (Test Kumesi)

| Sinif | F1 | Precision | Recall | Support |
|---|---|---|---|---|
| acil_servis | 0.5894 | 0.7908 | 0.4698 | 547 |
| doga_atmosferi | 0.5871 | 0.6351 | 0.5458 | 2631 |
| diger_hayvanlar | 0.5823 | 0.8005 | 0.4576 | 754 |
| su_sesleri | 0.5567 | 0.6301 | 0.4987 | 1486 |
| hava_olaylari | 0.5534 | 0.7385 | 0.4426 | 1410 |
| tarim_ciftlik | 0.5249 | 0.6135 | 0.4587 | 218 |
| dini_mekan | 0.4614 | 0.5224 | 0.4131 | 564 |
| insaat_sesleri | 0.3877 | 0.4307 | 0.3526 | 502 |

Dusuk performansin iki temel nedeni vardir: (1) siniflar arasi akustik benzerlik — insaat_sesleri ve endustri_fabrika gibi kategoriler benzer frekans iceriklerine sahiptir; (2) veri dengesizligi — kapi_sesleri (139 test segmenti) ve tarim_ciftlik (218 segment) gibi az ornekli siniflar genel performansi asagi cekmektedir. Bu durum, Asamali Tur 1 uretici artirmanin hedef siniflarini belirlemektedir.

## 4.4 Late Fusion Sonuclari




Sekil 7. Late fusion yontemlerinin bireysel modellerle karsilastirilmasi.

Tablo 5. Late Fusion Sonuc Tablosu

| Yontem | Val Macro-F1 | Test Macro-F1 | CNN'e Goreceli |
|---|---|---|---|
| Bireysel CNN | 0.6700 | 0.6716 | Referans |
| Esit Agirlik | 0.6568 | 0.6605 | -0.0111 |
| Val-F1 Agirlikli | 0.6603 | 0.6664 | -0.0052 |
| Meta-Learner (LogReg) | 0.7027 | 0.6397 | -0.0319 |
| **Oracle Ust Siniri** | **0.7778** | **0.7812** | **+0.1096** |

Meta-Learner val kumesinde 0.7027 gibi yuksek bir skor elde etmis; ancak test kumesinde 0.6397'ye duserek overfitting sergilemistir. Bunun temel nedeni, meta-learner'in 78-boyutlu giris uzayinda validasyon kumesine asiri uyum saglamasidir. Oracle ust siniri (0.7812) ile en iyi fusion yontemi (0.6664) arasindaki 0.115 bosluk, modellerin yuksek derecede korele hatalar yaptigina ve daha cesitli model mimarilerine (ornegin conformer ya da wav2vec2) ihtiyac duyulduguna isaret etmektedir.

# 5. Tartisma

## 5.1 CNN'in Ustunlugu

ResNet-18 tabanli CNN, her model ailesinde acik ara lider konumundadir. Bu sonuc birkac gozlemle aciklanabilir: (1) konvolusyonel mimari, spektrogramdaki yerel zaman-frekans kaliplari icin induktif bir on-bilgi saglar; (2) ImageNet on-egitiminden aktarilan dusuk-seviye ozellik detektoru agirliklar, ses veriyle ince ayar icin guclü bir baslangic noktasi olusturur; (3) spektrogramlar goruntulerle yeterince benzer oldugunden transfer learning etkili bir sekilde calismaktadir.

## 5.2 AST Transformerin Overfitting Davranisi

85.5M parametreli AST modeli, 9 epoch sonrasinda val loss artisina bagli overfitting sergiledi. Ozellikle dikkat cekici olan, train accuracy'nin epoch 7'de >%98'e ulasmisken val F1'in 0.60'ta plateolar yapmasidir. Bu durum, modelin egitim kumesini ezberledigi fakat genelleme yapamadigini gostermektedir. AST'nin potansiyelinden tam olarak faydalanmak icin SpecAugment, dropout artisi (0.2'den 0.4'e) ve gradual layer unfreezing gibi regularizasyon stratejilerinin denenmesi onerilmektedir.

## 5.3 LightGBM'in Rekabetci Performansi

El-yapimi 467-boyutlu ozellikler uzerinde calisan LightGBM'in 0.5857 test F1 ile derin ogrenme modellerine rekabetci yaklasabilmesi dikkat cekicidir. Bu sonuc; veri miktarinin sinirli oldugu, hesaplama butcesinin kisitlandigi ya da yorumlanabilirlik gereksinimlerinin on planda tutuldugu durumlarda geleneksel ML'nin gecerlili■ini dogrular. Gelecekte bu iki paradigmanin hibridlenmesi — ornegin CNN'in gizli katman ciktilarinin LightGBM'e girdi olarak verilmesi — arastirma konusu olabilir.

# 6. Sonuc ve Sonraki Adimlar

Bu calismada BBC Ses Arsivi uzerinde kapsamli bir karsilastirmali analiz gerceklestirilmistir. Temel bulgular soyle ozetlenebilir:

1. CNN (ResNet-18), Test Macro-F1=0.6716 ile en yuksek bireysel performansi gostermistir.
2. LightGBM+Optuna, klasik ML'de en iyi skor olan 0.5857'ye ulasmistir.
3. Late fusion, CNN'e istatistiksel olarak anlamli bir katki saglamadi (delta=+0.005).
4. Oracle analizi (0.7812) model cesitliligine ihtiyac oldugunu ortaya koymustur.
5. insaat_sesleri (F1=0.39) ve dini_mekan (F1=0.46), uretici artirma icin oncelikli hedeflerdir.

Tablo 6. Sonraki Arastirma Adimlari

| Asama | Gorev | Oncelik |
|---|---|---|
| 1.4 | Late Fusion (tamamlandi) | **BITTI** |
| 2.1 | 26 sinif x 5 Turkce prompt listesi (tamamlandi) | **BITTI** |
| 3.1 | AudioLDM kurulum + ilk uretim deneyi (50 klip/sinif) | YUKSEK |
| 3.2 | FAD olcumu — VGGish + CLAP karsilastirmali | YUKSEK |
| 3.3 | Iteratif artirma Tur 1: F1<0.5 siniflar | YUKSEK |
| 3.4 | AudioLDM Turkce CLAP fine-tuning | ORTA |
| 3.5 | Iteratif artirma Tur 2: fine-tuned model ile | ORTA |
| 4.1 | McNemar istatistiksel anlamlilik testleri | DUSUK |

| | | |
|---|---|---|
| 4.2 | Grad-CAM ve attention gorselle■tirmesi | DUSUK |